

Autoencoders

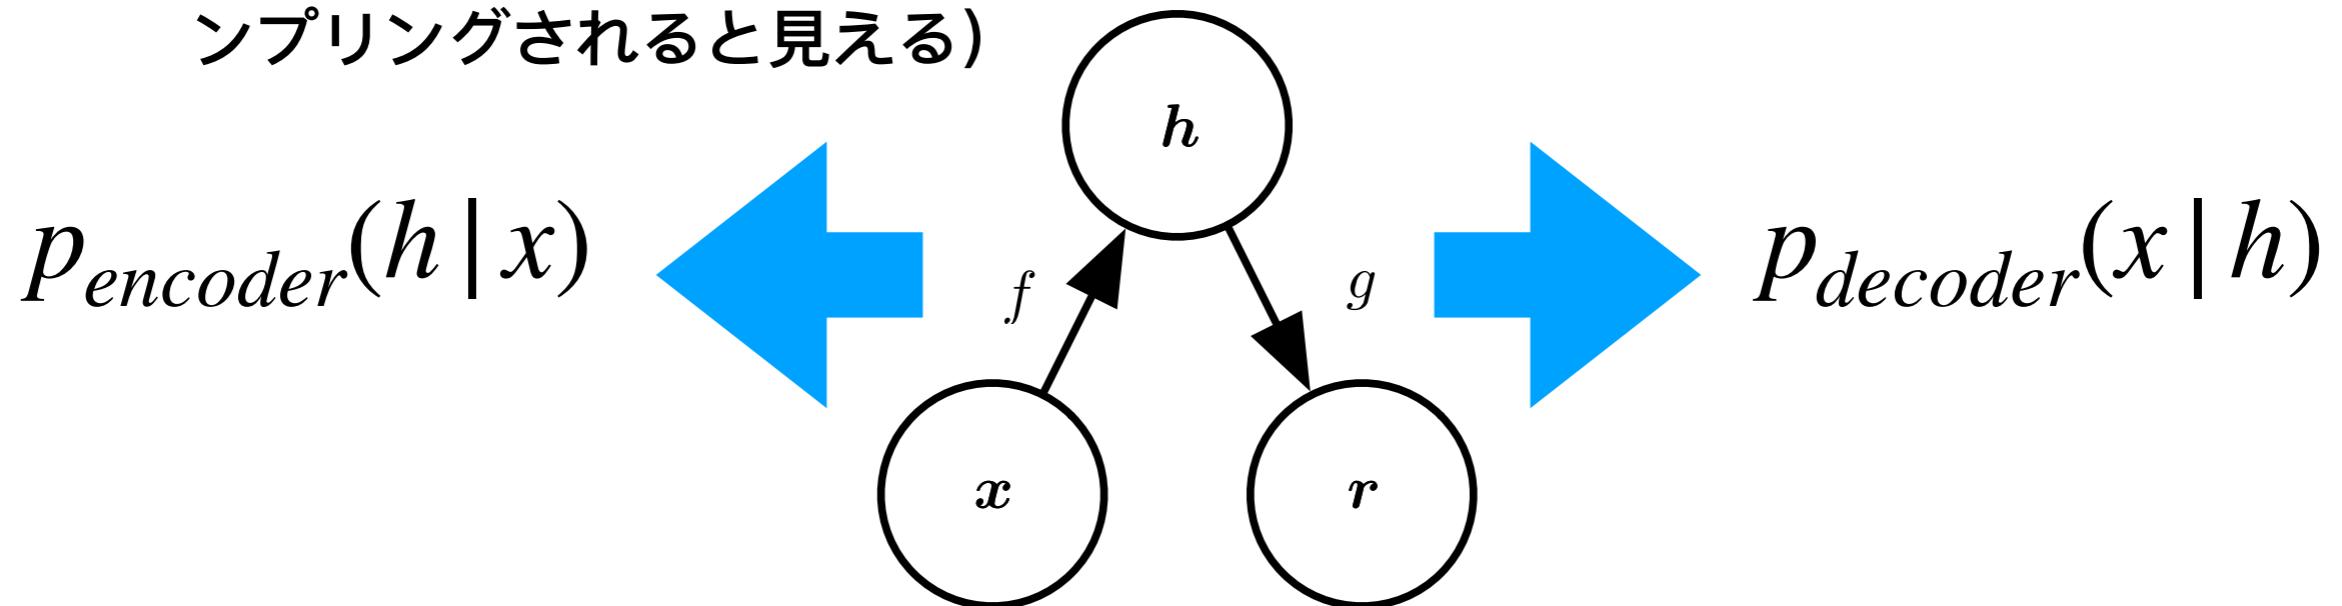
Chapter 14

楊 森 (Sen Yang) 2019/07/28

Autoencoders

- ・ Autoencoderは、**input**を、**output**にコピーする**neural network**。
- ・ 丸コピーは意味ないので、いろんな制限がある。
- ・ これらの制限で、autoencoderはコピーできるように、データの役に立つプロパティを学習できる。

現代autoencoderはencoderとdecoderを、決定的関数から、確率的マッピングに一般化した:
(ノイズ注入を含めるので、**output**が分布からサンプリングされると見える)



Autoencoderの応用:

- ・ 次元削減 (dimensionality reduction)
- ・ 情報検索 (information retrieval)

Undercomplete Autoencoders

- ・考え方①: h (code) dimensionを制限する (input dimensionと比べる)
- ・そうすると、autoencoderは一番顕著な (salient) 特徴を学習しないといけない

Autoencoderのloss function:

$$L(x, g(f(x)))$$

- ・線形decoder、 L がMSEの場合、undercomplete autoencoderはPCAと同じ結果を出す。
- ・非線形encoder、非線形decoderのcapacityが大きすぎると、undercomplete autoencoderはデータ分布に関する情報を学習しないことがある。
 - ・例えば、強すぎるnonlinear encoderが $x(i)$ をcode i に表して、decoderがcode i からサンプルにマップできるけど、code i には何の役に立つ情報もない。

Regularized (正則化された) Autoencoders

- 考え方②: モデルがコピー以外のプロパティを持つのを促すloss functionを使う
- encoderやdecoderを浅く、code sizeを小さくする制限はしない
- プロパティは以下の種類がある
 - sparsity of the representation (まばらな表現)
 - smallness of the derivative of the representation (小さい導関数の表現)
 - robustness to noise (ノイズへの頑健性) or to missing inputs (見つからないインプットへの頑健性)

Sparse Autoencoder:

$$L(x, g(f(x))) + \Omega(h) \quad \Omega(h) = \lambda \sum_i |h_i|$$

Denoising Autoencoder:

$$L(x, g(f(\tilde{x}))) \quad \tilde{x} \text{ はノイズを入れた後の } x \text{ のコピー}$$

Contractive (収縮性の) Autoencoder:

$$L(x, g(f(x))) + \Omega(h, x) \quad \Omega(h, x) = \lambda \sum_i \|\nabla_x h_i\|^2$$

Sparse Autoencodersへの考え方

Sparsity penaltyがコピータスクのregularizerであるのではなく、sparse autoencoderが、latent variableを持つ**generative model**の最尤推定であると考える。 (Rather than thinking of the sparsity penalty as a regularizer for the copying task, we can think of the entire sparse autoencoder framework as approximating maximum likelihood training of a generative model that has latent variables. p496)

$$\log p_{model}(x) = \log \sum_h p_{model}(h, x)$$

一つの高い可能性のhの点推定で近似する

$$\log p_{model}(h, x) = \log p_{model}(h) + \log p_{model}(x | h)$$

sparsityを誘導するために、**Laplace prior**を使う
(sparsityが強い場合、点推定も近似できるから?)

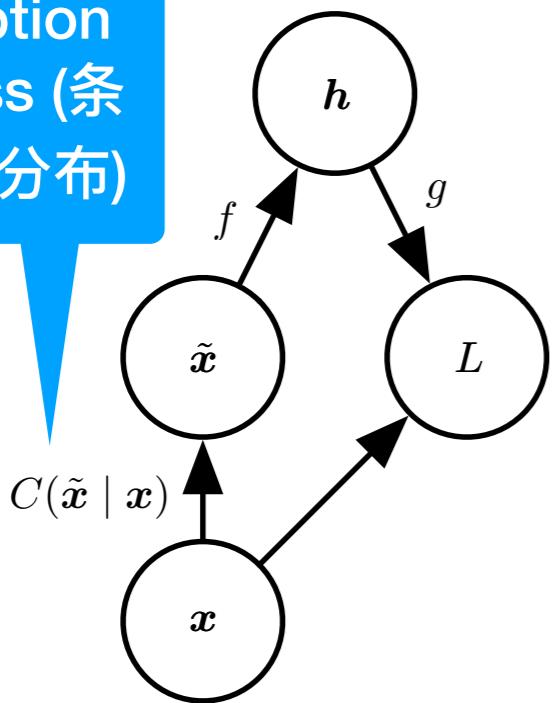
$$p_{model}(h) = \frac{\lambda}{2} e^{-\lambda|h_i|}$$

$$-\log p_{model}(h) = \sum_i (\lambda |h_i| - \log \frac{\lambda}{2}) = \Omega(h) + const$$

autoencoderをトレーニングするのは、生成モデルを近似的にトレーニングする方法の一種

Denoising Autoencoders

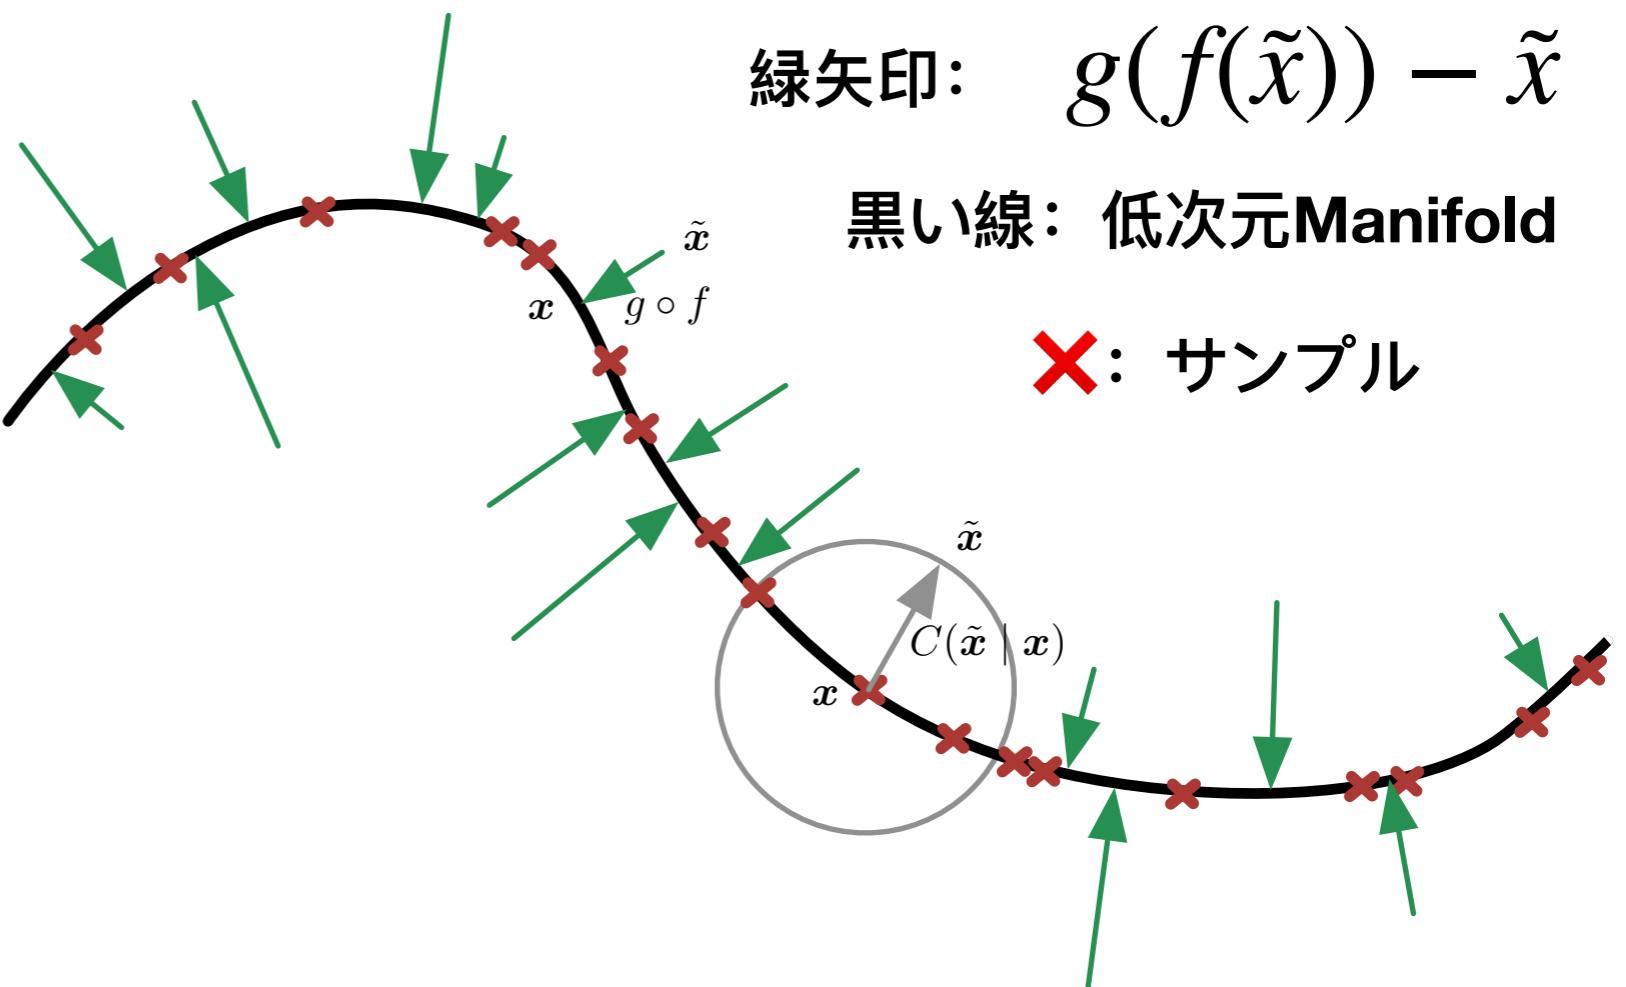
corruption process (条件付き分布)



DAEの一番強いプロパティは、 $g(f(x)) - x$ ベクトル場（緑矢印）を学習できること。

期待 (Expectation) :

$$-\mathbb{E}_{x \sim \hat{p}_{data}(x)} \mathbb{E}_{\tilde{x} \sim C(\tilde{x}|x)} \log p_{decoder}(x | h = f(\tilde{x}))$$



緑矢印: $g(f(\tilde{x})) - \tilde{x}$

黒い線: 低次元Manifold

×: サンプル

Denoising Autoencoder and Score Matching

Denoising Autoencoderが学習した $g(f(x)) - x$ ベクトル場 (vector field) は、 $\nabla_x \log p_{data}(x)$ スコア (gradient field) を予測する。

$\log p_{data}$ 勾配場を学習するのは、 P_{data} 自体の構造を学習する方法だ。

前提: Gaussian corruption

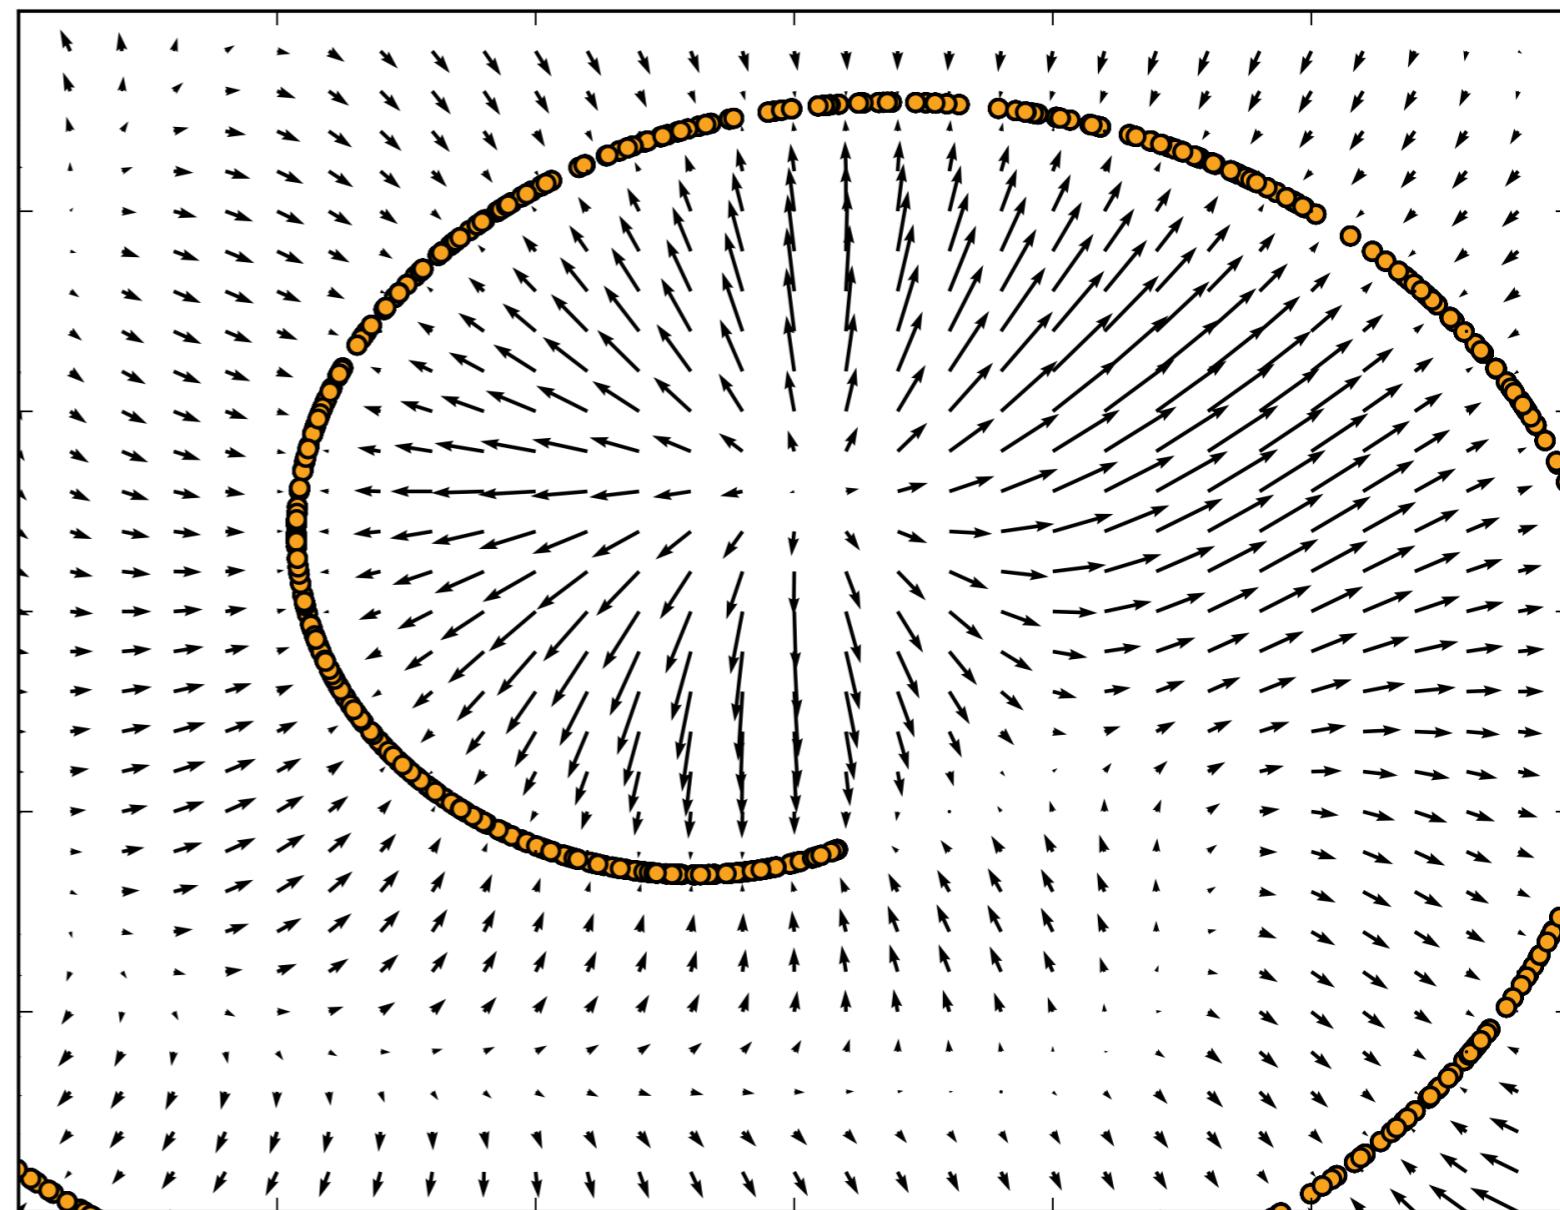
$$C(\tilde{x} = \tilde{x} | x) = \mathcal{N}(\tilde{x}; \mu = x, \sum = \sigma^2 I)$$

ベクトル場とスコアの関係: $\sigma \rightarrow 0$

$$\frac{r_\sigma(x) - x}{\sigma^2} \rightarrow \frac{\partial \log p(x)}{\partial x}$$

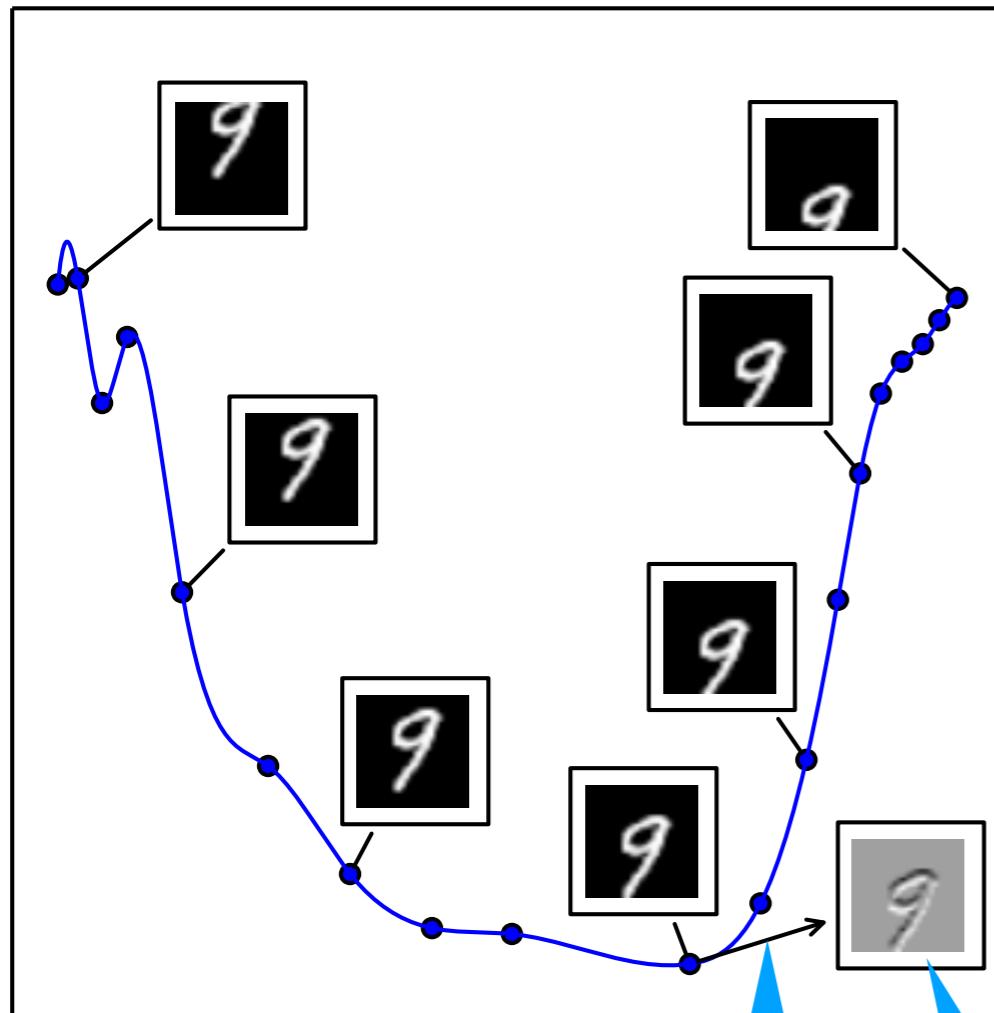
参考: Alain, G. and Bengio, Y. (2013). What regularized auto-encoders learn from the data generating distribution. In *ICLR'2013*

Denoising Autoencoder
が学習した $r(x) - x$
ベクトル場



Learning Manifolds with Autoencoders①

Manifold（多様体）の大切特性：接平面（tangent plane）の集合。d次元のmanifoldの接平面は、d基底から構成され、ローカル変化（variation）方向を示す。



上下移動の1D manifold。
tangent lineになっている。

Autoencoderトレーニングプロセスの2つめ：
① Decoderで x を再生できる表現 h を学習する
→ inputのvariation全部コピーしたい
② 制限や正則化を満たす
→ inputのvariation全部無視したい
結果的に、Autoencoderは x の再建に必要な変化
(variation)のみを表現する。
(represent only the variations that are needed to reconstruct training examples)

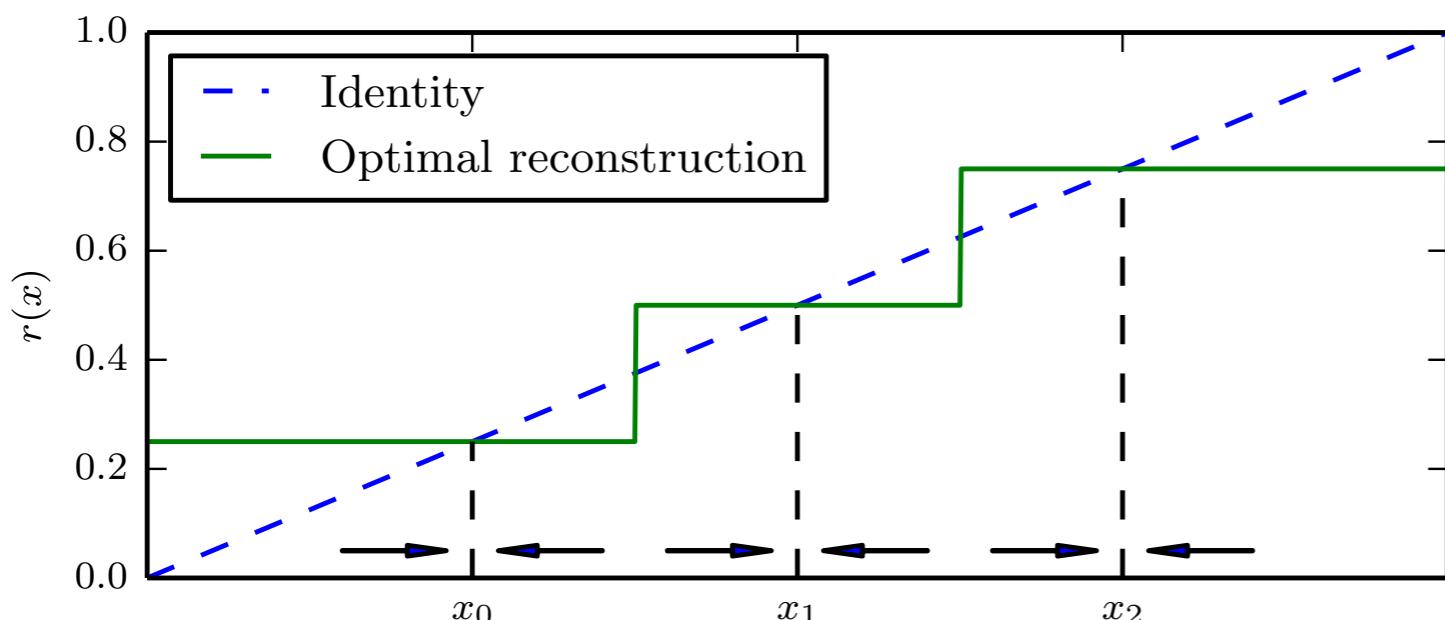
つまり、最終的に、Autoencoderは、Manifoldの接平面方向での変化のみに敏感に反応する。

このtangent方向に移動すると、ピクセルがどう変わる：
灰色（変わらない）、黒（暗くなる）、白（明るくなる）

Learning Manifolds with Autoencoders②

再建 (reconstruction) 関数を、データポイント周囲の擾動 (perturbation) に鈍感にさせて、Autoencoderはmanifold構造をキャプチャーできる

1Dデータの例: 0D多様体 (一つの点) の集合



青線: 同一関数 $r(x)=x$

黒矢印: $r(x)-x$ ベクトル

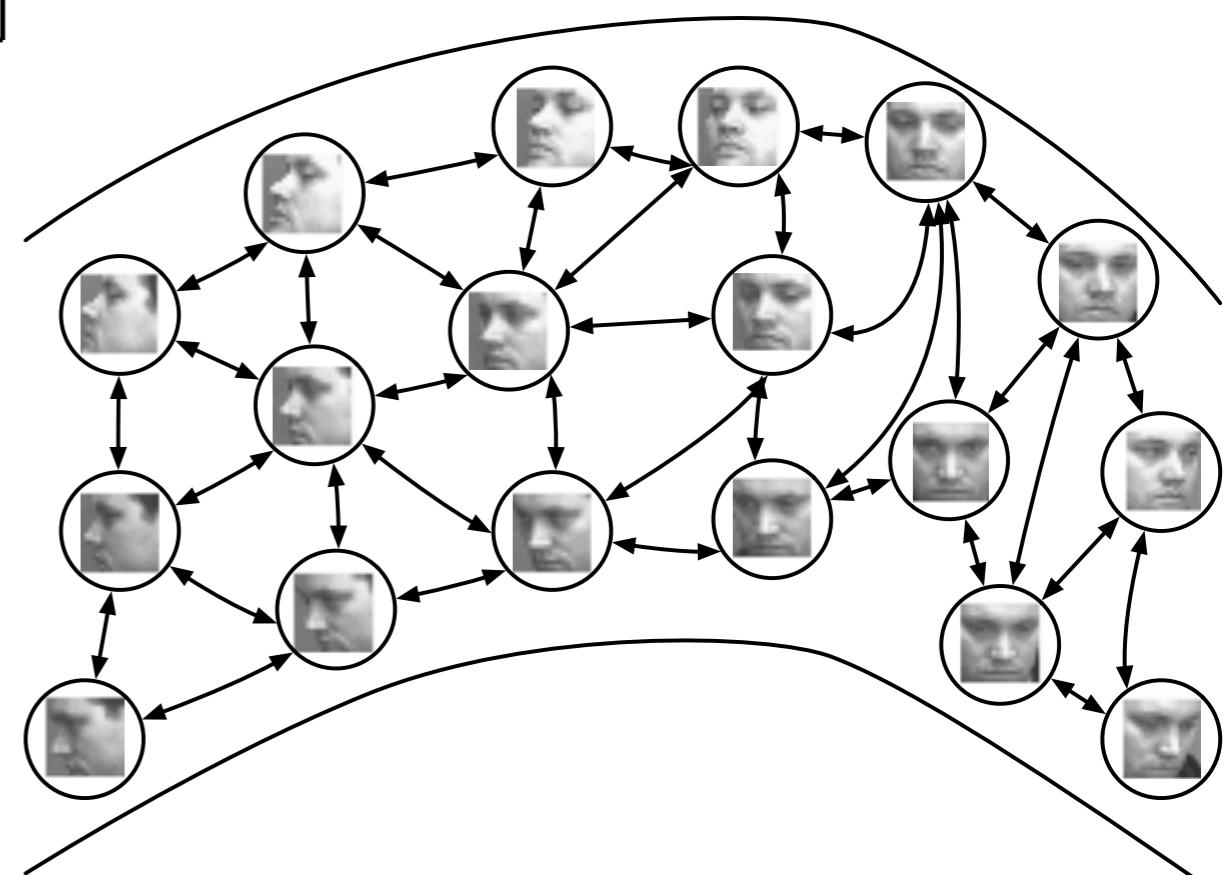
緑線:

- Autoencoderが学習した再建関数
- データポイント付近の $r(x)$ の導関数を小さくする
- Manifold間の導関数は大きい

Autoencoder以前のManifold学習手段: 最近傍

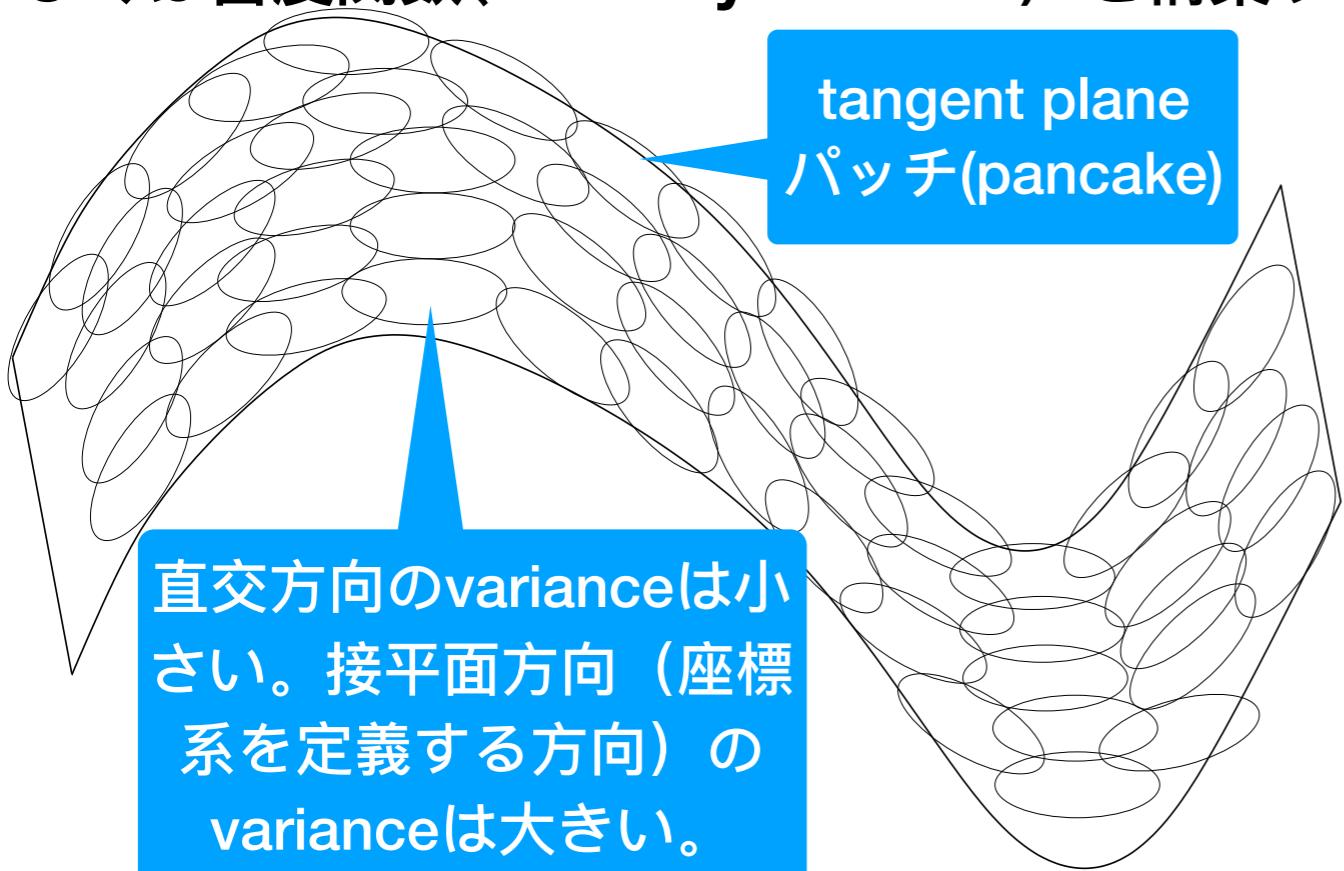
グラフベースのノンパラメトリック方法

- nodeに接平面を付ける
- 接平面の方向を、nodeとneighborsの差分の方向と、関連づける
- nodeにグローバル座標系 (Embedding) を付ける (次ページの図)
- 内挿 (interpolation) で新しいサンプルに一般化する

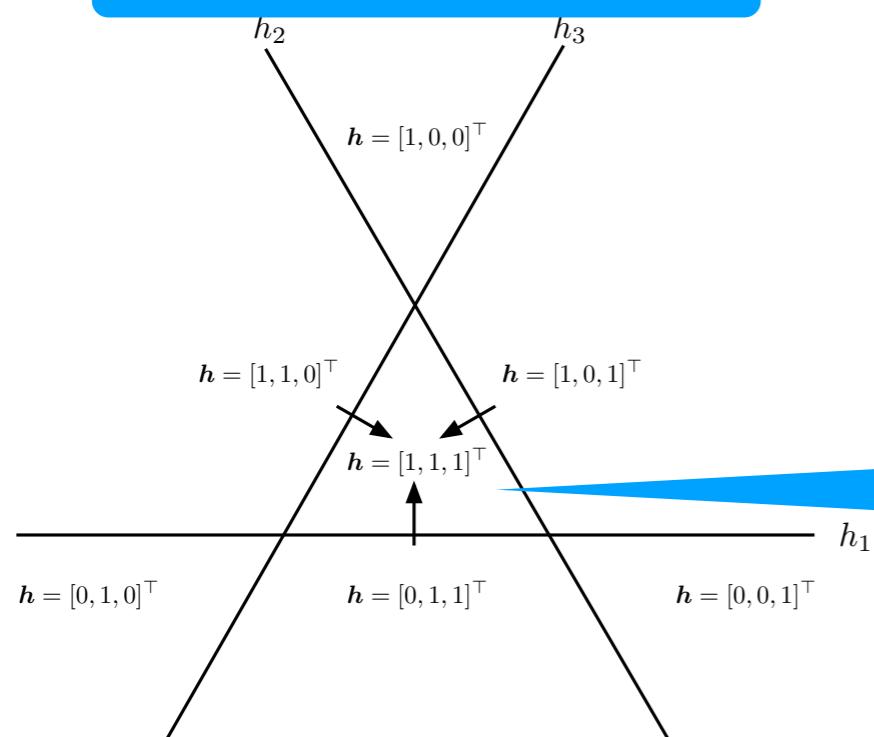


Learning Manifolds with Autoencoders② 続

(ノンパラメトリック方法) 接平面 (tangent plane) 集合からグローバル座標系 (もしくは密度関数、density function) を構築する



直交方向のvarianceは小さい。接平面方向 (座標系を定義する方向) の varianceは大きい。



分散表現スペース: 例
えば、 $h=[1,1,1]$ のサン
プルがなくても、
[1,1,1] regionをキャプ
チャーできる

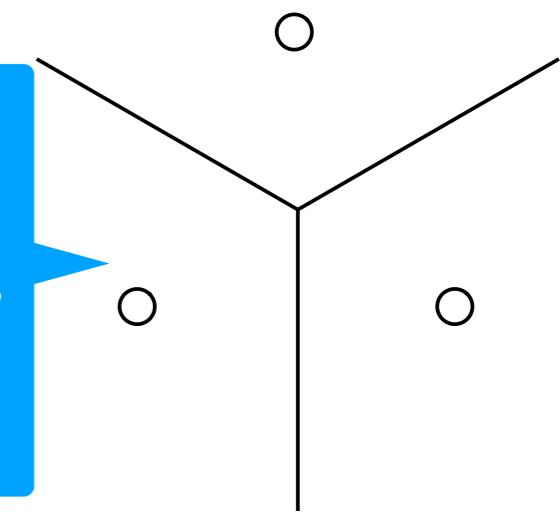
しかし、ノンパラメトリック方法の一番の
ディメリットは、複雑なManifoldを学習す
るために、たくさんサンプルが必要

理由:

- ・ノンパラメトリック方法は、新しいイ
ンпутに対して、内挿しかできない
- ・Manifoldがスムーズじゃない場合、
Manifoldの複雑なVariationをキャプ
チャーするために、たくさんサンプルが
必要

この課題が存在するので、分散表現 (distributed representation) や深層学習でManifoldをキャプ
チャーするのが進んでいる。

最近傍スペー
ス: 全ての
regionにサンプ
ルが必要



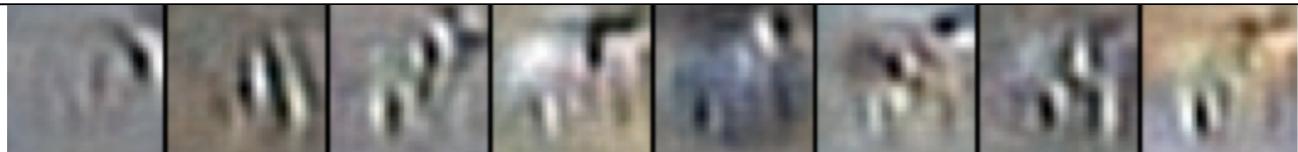
Contractive (収縮性の) Autoencoders

$$\Omega(h) = \lambda \left\| \frac{\partial f(x)}{\partial x} \right\|^2$$

Denoising autoencoderは再建関数 (reconstruction function) を小さい擾動に抵抗させよう

Contractive autoencoderは特徴抽出関数 (feature extraction function) を小さい擾動に抵抗させよう

- ①収縮というのは、Contractive Autoencoderのトレーニングで、J (ヤコビ行列) の特異値が1より小さくなる
- ②CAEの目標：Jの大きい特異値に対する方向は、Manifoldの接 (tangent) 方向になる

Input point	Tangent vectors
	
	Local PCA (no sharing across regions)
	
	Contractive autoencoder

CAEが予測した接ベクトル (tangent vector) は、オブジェクト (犬の頭や脚) の意味がある移動や変化を示せる。